

Untangling Equifinality: A Large-Sample Benchmark of Machine-Learning Models for Rainfall–Runoff Forecasting in Eurasian Basins

Эльдар Хузин

Московский физико-технический институт

Курс: My first scientific paper

Эксперт: Д. Абрамов

Консультант: Д. Абрамов

2025

Цель исследования

Цель

Исследовать эквивалентность моделей RF, XGBoost, LSTM, а также их способность выявлять гидрологические закономерности.

Задача

Сравнить одинаковые по точности модели в их способности выделять ключевые для бассейнов статические характеристики.

Решение

1. На обширном датасете кластеризовать бассейны рек по статическим признакам.
2. Сравнить модели по метрикам NSE, RMSE, MAE, MAPE.
3. Оценить вклад признаков через SHAP-значения.
4. Проанализировать компромисс “точность\вычислительная сложность\интерпретируемость”.



Beven, Keith и Andrew Binley (июль 1992). “The Future of Distributed Models: Model Calibration and Uncertainty Prediction”. В: *Hydrological Processes* 6.3, с. 279—298. DOI: [10.1002/hyp.3360060305](https://doi.org/10.1002/hyp.3360060305).



Kratzert, Frederik и др. (17 дек. 2019). “Towards Learning Universal, Regional, and Local Hydrological Behaviors via Machine Learning Applied to Large-Sample Datasets”. В: *Hydrology and Earth System Sciences* 23.12, с. 5089—5110. DOI: [10.5194/hess-23-5089-2019](https://doi.org/10.5194/hess-23-5089-2019).



“Spatial-Temporal Behavior of Precipitation Driven Karst Spring Discharge in a Mountain Terrain” (1 сент. 2022). В: *Journal of Hydrology* 612, с. 128116. DOI: [10.1016/j.jhydrol.2022.128116](https://doi.org/10.1016/j.jhydrol.2022.128116).

Вычислительный эксперимент

1. Предобработка данных


- 1.1 Корреляционный анализ и отбор статических признаков
- 1.2 Заполнение пропусков
- 1.3 Добавление лагов и статических атрибутов

2. Обучение

- 2.1 Выделение выборок (12/3)
- 2.2 Подбор гиперпараметров (Optuna)
- 2.3 Training

3. SHAP-анализ и другие метрики

$$\phi_i = \sum_{S \subseteq N \setminus \{i\}} \frac{|S|! (|N| - |S| - 1)!}{|N|!} [f(S \cup \{i\}) - f(S)]$$



Cluster	Rank 1	Rank 2
0	lat (Широта)	for_pc_sse (Площадь лесов)
1	crp_pc_sse (Пахотные земли)	pst_pc_sse (Пастбища)
2	gwt_cm_sav (Глубина ГВ)	for_pc_sse (Площадь лесов)

Ежедневные данные за период с 2008 по 2022 год с 1072 бассейнов.

prcp – количество осадков (мм/сут)

lvl_sm – уровень воды в реке (м) [deprecated]


t_min – минимальная температура (°C)

t_max – максимальная температура (°C)


t_mean – средняя температура (от почасовой) (°C)

q_mm_day – расход воды (мм/сут)

Monthly precipitation totals




Daily streamflow (q_mm_day)



Описание атрибутов

ID	Атрибут	
S03	Песок в почве (%)	snd_pc_sav
S01	Глина в почве (%)	cly_pc_sav
S02	Ил в почве (%)	slt_pc_sav
H05	Объём озёр (млн м ³)	lkv_mc_usu
H06	Объём водохранилищ (млн м ³)	rev_mc_usu
H04	Доля озёрной поверхности (%)	lka_pc_use
H03	Площадь затопления (%)	inu_pc_ult
H10	Глубина грунтовых вод (см)	gwt_cm_sav
H08	Площадь рек (га)	ws_area
P04	Географическая широта (°)	lat
P05	Географическая долгота (°)	lon
P01	Средняя высота над уровнем моря (м)	ele_mt_sav
P02	Средний уклон местности (°)	slp_dg_sav

Correlation Heatmap



Формальная постановка задачи

- ▶ Предсказать y на основе признаков x .
- ▶ Пусть $y \in \mathbb{R}^n$; $x \in \mathbb{R}^{n \times d}$;
- ▶ Набор данных: $\mathcal{D} = \{(x_i, y_i) \mid i = 1, \dots, n\}$;
- ▶ Класс моделей: $\mathcal{F}$;
- ▶ Оценка: $\hat{y}_i = f(x_i)$, $f \in \mathcal{F}$, $\hat{y} = (f(x_1), \dots, f(x_n))$.

$$f^* = \arg \min_{f \in \mathcal{F}} (\mathcal{L}(f, \mathcal{D}) + \Omega(f)) \quad (1)$$

Random Forest и Gradient Boosting

Модель:

$$f(x) = \sum_{l=1}^L \omega_l \mathbb{I}(x \in R_l).$$

Построение разбиений по критерию:

$$\mathcal{JG}(t,j) = \frac{1}{2} \left[\frac{(G_L)^2}{H_L + \lambda} + \frac{(G_R)^2}{H_R + \lambda} - \frac{G^2}{H + \lambda} \right] - \gamma,$$

где $G_{L,R}, H_{L,R}$ — суммы градиентов и гесссианов.

Random Forest

$$f_{\text{RF}}(x) = \frac{1}{B} \sum_{b=1}^B f^{(b)}(x)$$

Gradient Boosting



$$f_{\text{GB}}(x) = f^{(0)}(x) + \nu \sum_{b=1}^B f^{(b)}(x)$$

$$\mathbf{MAPE} = \frac{1}{n} \sum_{i=1}^n \left| \frac{\hat{y}_i - y_i}{y_i} \right|$$



$$\mathbf{Pseudo-MAPE}_{\delta} = \frac{1}{n} \sum_{i=1}^n \left(\sqrt{\left(\frac{\hat{y}_i - y_i}{y_i} \right)^2 + \delta^2} - \delta \right)$$

$$\mathbf{NSE} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2}, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$$

MAPE и Pseudo-MAPE



Результаты







Gradient Boosting

cluster	NSE	RMSE	MAE	MAPE	#
0	0.780	0.577	0.259	0.655	44 544
1	0.634	0.372	0.143	1.228	38 371
2	0.820	0.214	0.120	0.454	1 096
3	0.829	0.708	0.325	1.093	12 583





Random Forest

cluster	NSE	RMSE	MAE	MAPE	#
0	0.922	0.343	0.149	0.428	44 544
1	0.909	0.185	0.070	0.590	38 371
2	0.950	0.112	0.052	0.173	1 096
3	0.939	0.424	0.158	0.653	12 583

Результаты: Gradient Boosting



Результаты: Random Forest



- ▶ Выделенные моделями признаки не совпадают с основными кластерами, что требует дальнейшего изучения.
- ▶ Проявление эквивиальности наблюдалось в ходе проведения экспериментов, особенно с использованием Random Forest.